

ID26 模型校验实验报告

摘要

本报告对基于大语言模型的国际关系多智能体仿真系统（ID26）进行逐轮逐国的追随行为校验。校验场景为冷战前欧洲（1946Q1-1958Q2，50轮，每轮=3个月），共25个国家的两极体系。核心指标为追随行为F1分数，计算基于1150个逐轮逐国观测点（23个中小国家×50轮）。校验建立在一个关键概念区分之上：追随（Following）不等于同盟（Alliance）——追随是议题特定的领导偏好，不等同于冷战时期的阵营隶属。结果显示：追随F1=0.8231（Precision=0.8253, Recall=0.8209），处于Good水平。逐轮F1均值=0.8198，标准差=0.0681，最高轮次R26=0.9474，最低轮次R49=0.6000。两大超强独立性保护完美。误差结构中FP（错误追随）占比49.2%，FN（遗漏追随）占比50.8%。分阵营F1：西方阵营=0.9308，东方阵营=0.8193，中立/摇摆国=0.4602。

关键词：多智能体仿真；国际关系；模型校验；F1分数；追随行为；冷战；两极体系；逐轮校验

仿真编号：ID26 | 场景：冷战前欧洲（1946年） | 日期：2026-06-09 | 轮数：50轮（每轮=3个月） | 国家：25国（2大超强+23中小国） | 时间跨度：1946Q1-1958Q2

1 核心概念界定：追随不等于同盟

1.1 概念区分

在进行模型校验之前，必须首先明确追随与同盟是两个完全不同层次的概念。同盟（Alliance）是国家间通过正式或非正式条约建立的长期安全合作关系，具有制度化和持久性特征。在冷战两极格局下，同盟关系通过北约（NATO）和华沙条约组织（Warsaw Pact）制度化。追随（Following）则是在特定议题上对某一大国的政策偏好和领导认可，具有议题特定性和短期变动性。追随不要求制度化的同盟关系——即便是北约成员国，也可能在特定议题上采取独立立场；即便是不结盟运动的成员国，也可能在特定议题上追随某一大国。

1.2 冷战两极体系的特殊性

与一战前的多极体系不同，冷战时期（1946-1958）的国际关系呈现严格的两极格局。以苏联为首的东方阵营（USSR bloc）和以英美为首的西方阵营（Western bloc）几乎将整个欧洲划分为两个对立的势力范围。但这种划分并不等同于追随：

现象	同盟/ 阵营归属	实际追随行为	逻辑
芬兰化	无军事同盟	在安全议题上追随苏联	地缘安全迫使议题追随， 不等于制度同盟
法国退出北约军事一体化 (1966)	北约成员国	部分议题不追随美国	同盟框架内可存在议题不追随
南斯拉夫	不结盟	经济议题倾向于西方	不结盟不等于对所有议题中立
阿尔巴尼亚	华约成员 (至1968)	中苏分裂后追随中国	阵营叛离是典型的议题性追随转移

1.3 校验指标

本报告以追随行为F1分数为唯一核心校验指标。F1是Precision和Recall的调和平均。校验基于1150个逐轮逐国观测点（23个非大国×50轮），大国（苏联/俄罗斯、英国）作为体系领导者永远为独立决策，不参与F1计算。

2 校验方法

2.1 F1计算公式

$$P = TP / (TP + FP), \quad R = TP / (TP + FN), \quad F1 = 2PR / (P + R)$$

其中，TP（True Positive）为仿真追随目标与历史追随目标一致的情况；FP（False Positive）为仿真错误追随或不应追随却追随的情况；FN（False Negative）为仿真遗漏的追随（历史要求追随但仿真中立）；TN（True Negative）为仿真与历史均为中立的情况。

2.2 混淆矩阵定义

分类	定义
TP	仿真追随目标 = 历史追随目标（均非空）
FP	仿真追随目标 ≠ 历史追随目标，或仿真追随了但历史要求中立
FN	仿真中立，但历史要求追随某人
TN	仿真中立，历史也要求中立

2.3 历史地面真值数据（v5）

历史地面真值数据（v5版，由generate_history_v5.py生成）为逐轮（50轮×3个月）逐国（25国）的追随标注。每轮有一个明确的主导国际议题，涵盖战后重建、马歇尔计划、柏林封锁、朝鲜战争、斯大林逝世、华约建立、匈牙利革命、苏伊士危机等冷战关键事件。每个国家的追随目标基于该国在该议题上的实际外交政策立场确定。数据位于data/history/scene3_prewar_1946.json。

3 校验结果

3.1 整体结果

表1：追随行为F1整体结果

指标	数值	说明
F1	0.8231	综合校验指标
Precision	0.8253	追随预测准确率
Recall	0.8209	历史追随覆盖率
TP	770	正确追随
FP	163	错误追随
FN	168	遗漏追随
TN	49	正确中立
观测总数	1150	23国×50轮

逐轮F1统计：均值=0.8198，标准差=0.0681，最高R26=0.9474，最低R49=0.6000。

Precision大于Recall，表明误差以FN（遗漏追随）为主——模型倾向于过度保守。




图1：50轮追随F1逐轮变化，含5轮移动平均和冷战历史阶段标注。

Figure 3: Confusion Matrix (ID26, Cold War)




图3：整体混淆矩阵。

3.2 逐国结果

表2：各国追随F1详情（按F1降序排列）

国家	TP	FP	FN	TN	P	R	F1
Turkey	47	0	3	0	1.0000	0.9400	0.9691

国家	TP	FP	FN	TN	P	R	F1
Italy	46	0	4	0	1.0000	0.9200	0.9583
Luxembourg	46	0	4	0	1.0000	0.9200	0.9583
Netherlands	45	1	4	0	0.9783	0.9184	0.9474
Iceland	45	0	5	0	1.0000	0.9000	0.9474
Belgium	44	0	6	0	1.0000	0.8800	0.9362
Hungary	43	0	7	0	1.0000	0.8600	0.9247
Portugal	43	0	7	0	1.0000	0.8600	0.9247
Norway	43	0	7	0	1.0000	0.8600	0.9247
Romania	42	0	8	0	1.0000	0.8400	0.9130
Denmark	42	0	8	0	1.0000	0.8400	0.9130
Albania	41	0	9	0	1.0000	0.8200	0.9011
Bulgaria	40	0	10	0	1.0000	0.8000	0.8889
France	36	0	11	3	1.0000	0.7660	0.8675
Greece	38	0	12	0	1.0000	0.7600	0.8636
Poland	37	0	13	0	1.0000	0.7400	0.8506
Czechoslovakia	33	2	15	0	0.9429	0.6875	0.7952
Sweden	26	7	13	4	0.7879	0.6667	0.7222
Switzerland	21	12	9	8	0.6364	0.7000	0.6667
Yugoslavia	12	26	2	10	0.3158	0.8571	0.4615
Spain	0	39	0	11	0.0000	0.0000	0.0000
Finland	0	39	11	0	0.0000	0.0000	0.0000
Ireland	0	37	0	13	0.0000	0.0000	0.0000

最佳三国：Turkey(F1=0.97) / Italy(F1=0.96) / Luxembourg(F1=0.96)。最劣三国：Ireland(F1=0.00) / Finland(F1=0.00) / Spain(F1=0.00)。

Figure 2: Per-Country Following F1/P/R (ID26, Cold War)




图2：23个中小国家的F1/Precision/Recall并排柱状图。

Figure 8: Per-Country Precision-Recall Scatter (ID26)




图8：各国Precision-Recall散点图。

3.3 阵营维度分析

表3：冷战阵营F1对比

阵营	均值F1	包含国家
西方阵营	0.9308	France, Italy, Belgium, Netherlands, Luxembourg, Denmark, Norway, Portugal, Iceland
东方阵营	0.8193	Poland, Czechoslovakia, Romania, Hungary, Bulgaria, Albania, Yugoslavia
中立/摇摆	0.4602	Spain, Sweden, Turkey, Greece, Switzerland, Finland, Ireland

Figure 9: F1 by Cold War Bloc Alignment (ID26)




图9：冷战阵营F1分组柱状图。

3.4 大国独立性

国家	独立轮数	独立率
Russia	50/50	100%
UK	50/50	100%

两大超强在全部50轮中保持100%独立决策，大国独立性保护机制运行完美。

4 逐轮逐国可视化分析




图4：逐轮逐国追随正确性热力图。




图5：冷战两大阵营追随格局演化。

Figure 6: Great Power Independence (ID26)




图6：两大超强独立决策比率。




图7：逐轮TP/FP/FN叠层柱状图和各历史阶段F1箱线图。

5 讨论

5.1 结果评价

ID26在逐轮逐国校验中取得 $F1=0.8231$ ($P=0.8253$, $R=0.8209$)，已达到良好水平 ($F1 \geq 0.70$)，表明模型在冷战两极格局的追随行为历史复现方面取得了显著进展。显著优于随机基准（多分类问题随机 $F1$ 约等于0.25），表明模型具有超越随机水平的历史复现能力。

5.2 误差模式分析

- (1) 芬兰化的挑战：芬兰 $F1=0.00$ ，表现不佳，FP错误追随=TP正确追随比严重偏高，模型对芬兰化（地缘安全议题上追随苏联）识别能力不足。
- (2) 两极格局的僵化特征：与一战前多极体系不同，冷战两极格局下各阵营内部的追随关系更稳定。东方阵营国家 $F1=0.8193$ ，西方阵营 $F1=0.9308$ ，中立/摇摆国 $F1=0.4602$ 。中立摇摆国的 $F1$ 低于阵营国家，说明摇摆国的不确定性构成了模型预测的主要困难。

(3) 不结盟国家的追随困境：南斯拉夫 $F1=0.46$ 、瑞典 $F1=0.72$ 、瑞士 $F1=0.67$ ，这些国家在冷战时期采取不结盟或中立政策，但在具体议题上仍可能有追随行为。

5.3 模型优势

- (1) 精准追随者识别：
France/Italy/Poland/Turkey/Czechoslovakia/Belgium/Netherlands/Romania/Hungary/Greece/Bulgaria/Portugal/Luxembourg/Denmark/Norway/Albania/Iceland的 $FP \leq 2$ ，Precision极高。
- (2) 高 $F1$ 国家 ($F1 \geq 0.70$)：
Turkey/Italy/Luxembourg/Netherlands/Iceland/Belgium/Hungary/Portugal/Norway/Romania/Denmark/Albania/Bulgaria/France/Greece/Poland/Czechoslovakia/Sweden（共18国），占中小国家的78%。
- (3) 大国独立性保护：两大超强独立决策率100%。

5.4 改进方向

- (1) 冷战阵营僵化性的模型识别：两极格局下阵营内部追随高度稳定，但阵营边界国家的追随具有议题特定性，需引入议题-阵营交叉权重。
- (2) 不结盟运动的特殊语义：不结盟不等于在所有议题上中立，需为不结盟国家引入议题选择性追随机制。
- (3) 跨场景一致性：与ID22一战场景对比，分析模型在不同国际体系结构（多极vs两极）下的校验表现差异。

6 结论

本报告以逐轮逐国的精度对ID26冷战前欧洲仿真进行了系统校验。基于v5历史地面真值数据（50轮×23国=1150观测点），获得追随行为 $F1=0.8231$ （ $P=0.8253$, $R=0.8209$ ）。主要发现：（1） $F1$ 处于Good水平；（2）误差以FN（遗漏追随）为主；（3）西方阵营(Western bloc)和东方阵营(USSR bloc)的预测准确性存在差异；（4）中立和摇摆国（芬兰、瑞典、瑞士等）的追随行为预测仍具挑战性。建议后续模型迭代引入冷战阵营僵化性约束和不结盟语义特殊处理。

附录A：历史地面真值说明

本报告使用v5版历史地面真值数据（generate_history_v5.py生成）。每轮（3个月）有独立的议题定义和逐国追随标注。数据位于data/history/scene3_prewar_1946.json。涵盖1946Q1至1958Q2共50轮25国的冷战关键时期。

附录B：输出文件

文件	说明
ID26_模型校验报告.md	本报告
data/id26_results.json	完整校验数据
data/id26_round_details.json	逐轮详细数据
code/validate_id26_f1.py	校验脚本
figures/	9张图表

附录C：跨场景对比（与ID22一战场景）

指标	ID22 (一战前)	ID26 (冷战前)	差异
体系	多极体系(3大国)	两极体系(2大国)	—
国家数	19国	25国	+6
非大国数	16国	23国	+7
观测点数	800	1150	+350
F1	0.7457	0.8231	+0.0774
Precision	0.6916	0.8253	+0.1337
Recall	0.8089	0.8209	+0.0120