

正式实验设计：领导类型对追随格局与国际秩序的影响

一、研究问题与实验目标

核心研究问题：大国的领导集体类型（王道型/霸权型/强权型/昏庸型）如何影响中小国家的追随行为分布与国际秩序的涌现类型？

实验目标：在三个历史基线场景（多极1913、过渡1938、两极1946）上，每次仅改变一个大国的领导类型（单变量控制），观察体系层面的追随格局、主权尊重率与秩序类型相对于基线的系统性偏离。

二、基线条件（前测实验已建立）

三个历史场景的前测F1分数构成正式实验的对照基准：

场景	体系结构	大国 (power_share>0.10)	基线领导类型	前测F1
场景一 (Scene 1)	多极体系 (1913)	GMY · RUS · UKG	GMY=强权, RUS=强权, UKG=王道	ID22: 0.746
场景二 (Scene 2)	多极→ 两极过渡 (1938)	RUS · GMY · UKG	RUS=霸权, GMY=强权, UKG=王道	ID25: 0.713
场景三 (Scene 3)	两极体系 (1946)	RUS · UKG	RUS=强权, UKG=王道	ID26: 0.823

基线说明：基线的三个基线场景（Scene 1/2/3）本身也是反事实仿真——所有国家糊名，LLM在不知晓真实国家身份的情况下凭国力数据和战略关系做出决策。F1分数衡量仿真输出与历史地面真值（逐轮逐国追随标注）的一致程度。正式实验中的每个变体场景均以对应基线的F1为比较基准。

三、实验设计原则

3.1 单变量控制

每个实验组仅改变**一个大国**的领导类型参数，其余所有条件——国力数据（CINC）、战略关系（同盟/冲突/伙伴）、国家列表、议题序列、profile加载规则——与对应基线场景完全一致。当实验改变了某大国的领导类型时，该国的历史行为心理学档案（leader_profile）自动抑制，确保profile中与该类型不匹配的行为权重不污染实验结果。

3.2 糊名机制

仿真运行期间所有国家以糊名呈现（如“强国甲”“中等国甲”“小国甲”），LLM不知晓所代表的是哪个具体国家。糊名状态贯穿决策、追随投票和领导竞争的全部三个阶段。**这一机制确保F1分数的变化仅归因于领导类型的参数操作，而非LLM对历史结果的事后知识**——事实上，基线F1（ID22: 0.746, ID25: 0.713, ID26: 0.823）本身就是在糊名条件下取得的，三个场景的F1差异反映的是体系结构对追随可预测性的客观影响，而非模型的“聪明程度”。

3.3 Profile抑制机制

系统自动检测智能体的 leader_type 是否匹配该场景/国家的 profile 预期类型（_SCENE_EXPECTED_TYPE）。当类型不匹配时（如Scene 10中GMY的 leader_type 从“强权型”变为“王道型”），GMY的强权型历史档案被自动抑制为 None ——LLM只能看到王道型的通用行为权重规则，而不会收到任何原强权型人格的权重注入。这保证了实验中改变的是**纯粹的类型规则**，而非类型规则与历史人格的混合效应。

四、实验矩阵

4.1 场景一：多极体系（1913年欧洲，19国）—— 9组

基线： GMY=强权型, RUS=强权型, UKG=王道型, FRN=霸权型, AUH=昏庸型（Scene 1）

Scene ID	实验编号	操作	理论焦点
10	S1-G1 (GMY强权→王道)	德国：强权型	若德国1913年受道义约束、遵守国际规范，七月危机能否避免？ 追随格局是否从极化对抗转向多边协调？

Scene ID	实验编号	操作	理论焦点
		→ 王道型	
11	S1-G2 (GMY强权 →霸权)	德国： 强权型 → 霸权型	若德国以制度工具主义和双重标准替代纯军事强制， 中小国家的追随是更稳定还是更分散？
12	S1-G3 (GMY强权 →昏庸)	德国： 强权型 → 昏庸型	若德国决策系统非理性化， 多极均势是否以不同路径瓦解？霸权真空由谁填补？
13	S1-R1 (RUS强权 →王道)	俄国： 强权型 → 王道型	若俄国受道义约束且不诉诸军事总动员， 巴尔干危机能否通过外交框架降级？
14	S1-R2 (RUS强权 →霸权)	俄国： 强权型 → 霸权型	若俄国以规则主导和利益计算替代军事威胁， 法俄同盟的性质是否改变？
15	S1-R3 (RUS强权 →昏庸)	俄国： 强权型 → 昏庸型	若俄国决策彻底失能，其追随者（塞尔维亚等） 转向何方？体系解体时序？
16	S1-U1 (UKG王道 →强权)	英国： 王道型 → 强权型	若英国放弃道义约束以纯军事力量维持均势， 体系秩序类型如何变化？
17	S1-U2 (UKG王道 →霸权)	英国： 王道型 → 霸权型	若英国以双重标准运作（殖民地强制/欧洲规范）， 追随格局是否出现地域性分裂？

Scene ID	实验编号	操作	理论焦点
18	S1-U3 (UKG王道→昏庸)	英国： 王道型 → 昏庸型	若体系内唯一的王道型领导者决策瘫痪，是否出现领导者真空？真空由德国还是法国填补？

4.2 场景二：过渡体系（1938年欧洲，28国）—— 9组

基线：RUS=霸权型, GMY=强权型, UKG=王道型（Scene 2）

Scene ID	实验编号	操作	理论焦点
19	S2-R1 (RUS霸权→王道)	苏联： 霸权型 → 王道型	若斯大林受道义约束、不以势力范围为核心诉求，东欧中小国家的安全选择空间是否拓宽？
20	S2-R2 (RUS霸权→强权)	苏联： 霸权型 → 强权型	若苏联以纯军事逻辑行动（扩张仅靠武力、无视制度形式），冷战两极格局是否更早固化？追随的强制成分是否上升？
21	S2-R3 (RUS霸权→昏庸)	苏联： 霸权型 → 昏庸型	若苏联决策系统紊乱（无法计算性利用德苏条约和军事缓冲），对德战争进程、东欧追随时序的偏离？
22	S2-G1 (GMY强权→王道)	德国： 强权型 → 王道型	若希特勒受道义约束、通过外交谈判修正凡尔赛体系，是否存在非战争路径？中小国家对德的追随是否从恐惧转向认同？
23	S2-G2 (GMY强权→霸权)	德国： 强权型 → 霸权型	若纳粹以规则话语和制度工具主义包装扩张（对大国用道义话语、对小国用强制），绥靖是否延长？追随是否更稳定？

Scene ID	实验编号	操作	理论焦点
24	S2-G3 (GMY强权→昏庸)	德国： 强权型 → 昏庸型	若德国决策紊乱（同时多线挑衅、无法完成战略规划），战争进程如何偏离？追随德国的阵营是否更早瓦解？
25	S2-U1 (UKG王道→强权)	英国： 王道型 → 强权型	若无绥靖而强硬对抗 (1938年即以军事手段回应每一步扩张)，大战是否提前？英国追随者数量与稳定性？
26	S2-U2 (UKG王道→霸权)	英国： 王道型 → 霸权型	若张伯伦式霸权逻辑（牺牲小国换时间）成为全期制度性策略，追随英国的中小国家是否因信任流失而转向？
27	S2-U3 (UKG王道→昏庸)	英国： 王道型 → 昏庸型	若英国决策系统失灵（无法形成连贯对德政策），欧洲是否因缺乏抗衡力量而全线沦陷？

4.3 场景三：两极体系（1946年欧洲，25国）—— 6组

基线：RUS=强权型, UKG=王道型（Scene 3）

Scene ID	实验编号	操作	理论焦点
28	S3-R1 (RUS强权→王道)	苏联： 强权型 → 王道型	若战后苏联受道义约束 (东欧通过多边制度安排而非军事强制管理)，冷战能否避免或形态不同？东欧追随的自愿性是否上升？
29	S3-R2 (RUS强权→霸权)	苏联： 强权型 → 霸权型	若苏联以制度工具主义和双重标准替代纯军事强制 (经互会/华约为真正的多边框架而非控制的制度化)，阵营稳定性如何变化？

Scene ID	实验编号	操作	理论焦点
30	S3-R3 (RUS强权→昏庸)	苏联： 强权型→昏庸型	若苏联决策系统紊乱（继承斗争扩大化、对外行为不可预测），东欧阵营的凝聚力如何？是否出现多个"南斯拉夫式"脱离？
31	S3-U1 (UKG王道→强权)	英国： 王道型→强权型	若英国以军事力量维持帝国（拒绝去殖民化、强制手段管理势力范围），西方阵营的性质如何改变？追随英国的西欧国家是否减少？
32	S3-U2 (UKG王道→霸权)	英国： 王道型→霸权型	若英国以霸权逻辑运作（公开道义话语+私下帝国特权，如苏伊士模式贯穿全期），西方阵营团结度与法美关系如何？
33	S3-U3 (UKG王道→昏庸)	英国： 王道型→昏庸型	若英国决策系统瘫痪（无法推动北约筹建、欧洲一体化或有序去殖民化），西欧领导真空由法国还是美国（不在列表中）填补？

五、实验分组与理论检验层级

24组实验按理论关切分为三个检验层级：

层级一：王道 ↔ 强权的极性轴检验（最核心，6组）

比较王道型和强权型对追随格局的方向性影响。理论预期：王道型大国吸引更多**自愿性**追随（基于议题认同与规范感召），强权型大国的追随以**强制性**为基础（基于军事威慑与生存压力）。两组类型下中小国家的追随稳定性应有系统性差异。

关键组：**S1-G1**（GMY强权→王道）、**S1-U1**（UKG王道→强权）、**S2-G1**（GMY强权→王道）、**S2-U1**（UKG王道→强权）、**S3-R1**（RUS强权→王道）、**S3-U1**（UKG王道→强权）

层级二：霸权型的中间地带检验（9组）

霸权型（工具性道义/双重标准）在追随格局上的表现更接近王道型还是强权型？理论预期：霸权型追随的稳定性高于强权型但低于王道型——双重标准在短期降低成本但长期侵蚀战略信誉。

关键组：S1-G2, S1-R2, S1-U2, S2-G2, S2-R1(对照), S2-U2, S3-R2, S3-U2

层级三：昏庸型的体系瓦解效应（9组）

当一个或多个大国变为昏庸型时，体系秩序类型是否系统性地向恐怖平衡方向滑动？理论预期：昏庸型大国无法维持稳定的追随关系，其追随者流失速度显著快于其他三种类型，且流失方向不可预测（±0.2随机波动效应）。

关键组：S1-G3, S1-R3, S1-U3, S2-G3, S2-R3, S2-U3, S3-R3, S3-U3

六、分析指标与数据提取

每组实验运行50轮后提取以下时序数据：

指标	提取方式	比较对象
逐轮追随矩阵	每轮每个中小国家的追随对象	对应场景基线
秩序类型序列	每轮四象限判定（规范接纳/不干涉/大棒威慑/恐怖平衡）	对应场景基线 + 历史地面真值
主权尊重率时序	respect_sov行为占比	对应场景基线
追随集中度（HHI）	赫芬达尔指数衡量追随的极化/分散程度	对应场景基线
阵营转换频率	每国跨阵营追随变更次数/总轮次	对应场景基线
追随动摇轮次	追随与历史地面真值偏离的轮次占比	前测基线F1

七、实施建议

- 1. 优先跑层级一（6组），初步分析王道↔强权极性轴效应后再决定是否跑全部24组

2. 三个场景的实验可**并行启动**（场景之间完全独立，无共享状态）
3. 每个实验场景的创建方式与基线完全一致：通过API调用对应 scene_id （10-33） 一键创建项目
4. 建议最小实验集（如果时间资源受限）：**6组**——每场景选最极端的两个反事实：
 - Scene 1: **S1-G1**（GMY→王道） + **S1-U1**（UKG→强权）
 - Scene 2: **S2-G1**（GMY→王道） + **S2-U1**（UKG→强权）
 - Scene 3: **S3-R1**（RUS→王道） + **S3-U1**（UKG→强权）

八、场景创建速查表

Scene ID	实验编号	基线场景	修改国家	修改内容	复用关系
1	基线	—	—	—	Scene 1 关系
2	基线	—	—	—	Scene 2 关系
3	基线	—	—	—	Scene 3 关系
10	S1-G1（GMY强权→王道）	1	GMY	强权→王道	Scene 1 关系
11	S1-G2（GMY强权→霸权）	1	GMY	强权→霸权	Scene 1 关系
12	S1-G3（GMY强权→昏庸）	1	GMY	强权→昏庸	Scene 1 关系
13	S1-R1（RUS强权→王道）	1	RUS	强权→王道	Scene 1 关系
14	S1-R2（RUS强权→霸权）	1	RUS	强权→霸权	Scene 1 关系
15	S1-R3（RUS强权→昏庸）	1	RUS	强权→昏庸	Scene 1 关系

Scene ID	实验编号	基线场景	修改国家	修改内容	复用关系
16	S1-U1（UKG王道→强权）	1	UKG	王道→强权	Scene 1 关系
17	S1-U2（UKG王道→霸权）	1	UKG	王道→霸权	Scene 1 关系
18	S1-U3（UKG王道→昏庸）	1	UKG	王道→昏庸	Scene 1 关系
19	S2-R1（RUS霸权→王道）	2	RUS	霸权→王道	Scene 2 关系
20	S2-R2（RUS霸权→强权）	2	RUS	霸权→强权	Scene 2 关系
21	S2-R3（RUS霸权→昏庸）	2	RUS	霸权→昏庸	Scene 2 关系
22	S2-G1（GMY强权→王道）	2	GMY	强权→王道	Scene 2 关系
23	S2-G2（GMY强权→霸权）	2	GMY	强权→霸权	Scene 2 关系
24	S2-G3（GMY强权→昏庸）	2	GMY	强权→昏庸	Scene 2 关系
25	S2-U1（UKG王道→强权）	2	UKG	王道→强权	Scene 2 关系
26	S2-U2（UKG王道→霸权）	2	UKG	王道→霸权	Scene 2 关系
27	S2-U3（UKG王道→昏庸）	2	UKG	王道→昏庸	Scene 2 关系
28	S3-R1（RUS强权→王道）	3	RUS	强权→王道	Scene 3 关系
29	S3-R2（RUS强权→霸权）	3	RUS	强权→霸权	Scene 3 关系

Scene ID	实验编号	基线场景	修改国家	修改内容	复用关系
30	S3-R3（RUS强权→昏庸）	3	RUS	强权→昏庸	Scene 3 关系
31	S3-U1（UKG王道→强权）	3	UKG	王道→强权	Scene 3 关系
32	S3-U2（UKG王道→霸权）	3	UKG	王道→霸权	Scene 3 关系
33	S3-U3（UKG王道→昏庸）	3	UKG	王道→昏庸	Scene 3 关系

本文档是"基于大语言模型的国际关系多智能体仿真系统"论文的组成部分，用于说明正式实验阶段的反事实实验设计与操作化方案。